# FAKE NEWS

THE CLASSIFICATION PROBLEM APPLIED TO BRAZILIAN NEWS

**ALEX AKIRA OKUNO** 



## #1 Understand what is fake news!





Estranho pedido de doleiros promete movimentar Justiça de Curitiba



Investigações da Operação Lava Jato surpreendem com revelação de caráter mundial



Moro deve liberar os R\$ 9.6 milhões de Lula. Basta que o petista prove que ganhou o dinheiro honestamente



Mãe reage a assalto e elimina bandido da face da Terra

# HEAVY-BIASED CONTENT! SOMETIMES, CLICKE

## #2 We need a classified DATABASE



The source and the way news are written carry a lot of meaningful information

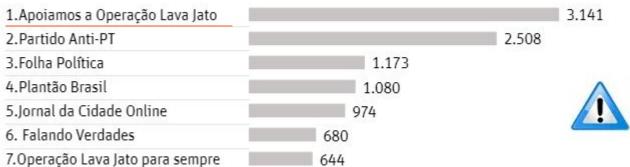


Search for proven doubtful news sources and assume its content as fake news, and vice-versa for non-fake news



Intensive work on Web Scraping

#### MAIORES PÁGINAS DE 'FAKE NEWS'\*\* Média de interações por post (out-nov.2017)



361



Fonte: Folha de S. Paulo, 8 Fev. 2018

8. Política na Rede

https://www1.folha.uol.com.br/poder/2018/02/fake-news-gan ha-espaco-no-facebook-e-jornalismo-profissional-perde.shtml

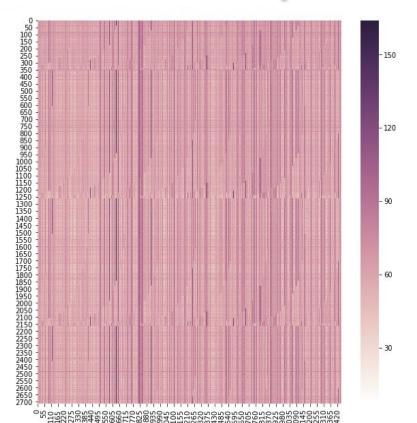
## BERAIS

### Possible Problem: Leakage

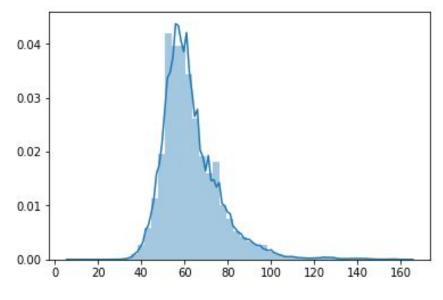




#### Levenshtein Distances Matrix Heatmap



## Levenshtein Distances Distribution





Avg. L. Distance: 62.96 Avg. Title Length: 69.97

### #3 Clean "junk" words

Facebook doará 5 centavos para cada compartilhamento de fotos #boato Chineses comem bebês para aumentar desempenho sexual #boato Suposta fraude da Mega-Sena se espalha na internet #boato Homem está no negócio de venda de meninas e meninos #boato Mamografia pode causar câncer na tireoide #boato CNN alerta para vírus na atualização do Windows Live #boato Batom com chumbo causa câncer #boato

Avião da Malaysia Airlines foi sequestrado por ovnis,

Vírus: homem ao fazer teste de fidelidade desc...

Pegadinha: confira fotos do novo iPhone 6, que...

Informação errada: Lula apoia genocídio de 3 m...

Foto falsa: Edir Macedo mostra banheira de our...

Notícia falsa: Famílias de presos vão receber ...

Boato: SBT afasta Rachel Sheherazade do ar apó...

Para curtir e não acreditar: 7 sites de notíci...

Mentira: profecia em culto evangélico apontava...

Mentira: sheik árabe acerta placar de Brasil e...

Alerta falso: novela Meu Pedacinho de Chão é d...

## **#4 Text Feature Engineering**

#### **TF-IDF Features**

For a term i in document j:

$$w_{i,j} = tf_{i,j} \times \log\left(\frac{N}{df_i}\right)$$

 $tf_{i,j}$  = number of occurrences of i in j  $df_i$  = number of documents containing iN = total number of documents **Embedding Word Vectors** 

- ── Word2Vec, Wang2Vec, FastText, Glove
- Available in Portuguese
- → Pre-trained or not

INFORMATIONAL TRADEOFF



## **#5 Classification Algorithms**

$$y_i = \begin{cases} 0, & \text{if fake news} \\ 1, & \text{otherwise} \end{cases}$$
$$\hat{y_i} = f(X_i; \hat{\theta})$$

 $\min_{\theta} J(\theta)$ 

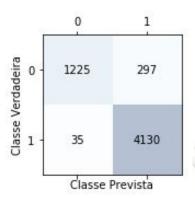


### **Logistic Regression**

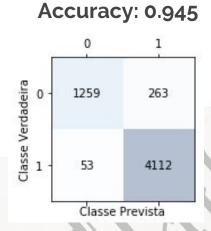
**TF-IDF Features** 

#### **No Stop Words**

Accuracy: 0.941



#### **Stop Words Included**





Em entrevista, Moro fala em reação, cita risco de morte e dá duríssimo recado aos bandidos do Brasil Sua notícia foi classificada como FALSA com probabilidade de 93.36%

Bolsonaro ganha em disparada na contagem de votos do IBGE Sua notícia foi classificada como FALSA com probabilidade de 92.15%

Lula condenado à 10 anos de cadeia pelo caso do Triplex Sua notícia foi classificada como FALSA com probabilidade de 85.31%

Lula ordena a prisão de Sérgio Moro Sua notícia foi classificada como FALSA com probabilidade de 98.82%

Sua notícia foi classificada como VERDADEIRA com probabilidade de 61.02%

Terremoto no Brasil destroi cidades no Alagoas

Dilma reassumiu a presidência após prisão de Michel Temer Sua notícia foi classificada como FALSA com probabilidade de 95.82%

Michel Temer assume presidência do Brasil Sua notícia foi classificada como FALSA com probabilidade de 79.86%

Toffoli propõe estender restrição ao foro para todas as autoridades Sua notícia foi classificada como VERDADEIRA com probabilidade de 73.31%

Intenção de votos em Bolsonaro dispara no mês de Outubro Sua notícia foi classificada como FALSA com probabilidade de 76.2%

#### **XGBoost**

#### **Word Embedding Features - Accuracies**

- Word2Vec CBOW: 0.926
- Word2Vec Skipgram: 0.938
- FastText CBOW: 0.935
- FastText Skipgram: 0.934
- Wang2Vec CBOW: 0.934
- Wang2Vec Skipgram: 0.935
- Glove: 0.933



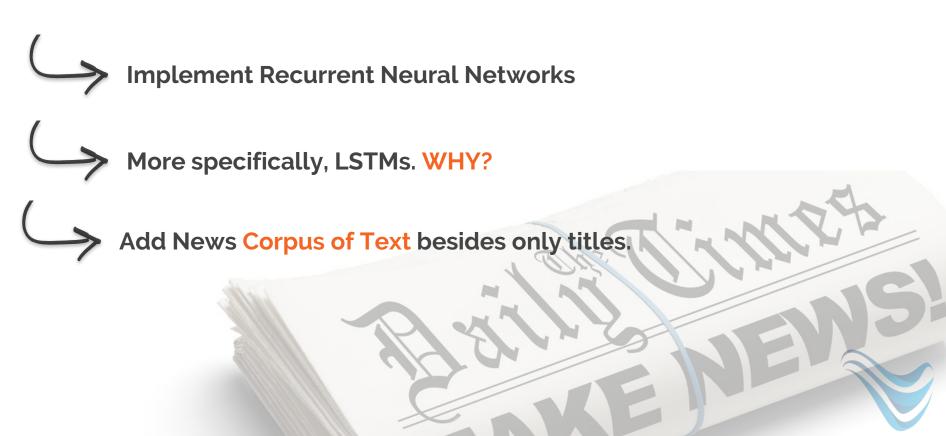
#### Feedforward Neural Network

#### Word2Vec Skipgram Features

- 2 Hidden Layers (200,100)
- Great Dropouts (0.5, 0.7)
- Batch Normalization



## **#5 Future Improvements**



## THANKS!

https://github.com/AkiraOkuno https://www.linkedin.com/in/alex-akira-okuno-12607a111/ akira.okuno@outlook.com